

Alfabetos, Cadenas y Lenguajes

Juan Mendivelso

Universidad Nacional de Colombia
Facultad de Ciencias
Departamento de Matemáticas

Presentación basada en las Notas de Clase del Profesor Rodrigo De Castro

Outline

- 1 Alfabetos y Cadenas
 - Definiciones Básicas de Alfabetos y Cadenas
 - Definiciones y Demostraciones Recursivas
- 2 Lenguajes
 - Definición
 - Operaciones entre Lenguajes
- 3 Lenguajes Regulares
 - Lenguajes y Expresiones Regulares
 - Expresiones Regulares en UNIX
 - Aplicaciones de de Expresiones Regulares

Outline

- 1 Alfabetos y Cadenas
 - Definiciones Básicas de Alfabetos y Cadenas
 - Definiciones y Demostraciones Recursivas
- 2 Lenguajes
 - Definición
 - Operaciones entre Lenguajes
- 3 Lenguajes Regulares
 - Lenguajes y Expresiones Regulares
 - Expresiones Regulares en UNIX
 - Aplicaciones de de Expresiones Regulares

Alfabeto

Alfabeto

Conjunto finito no vacío cuyos elementos se llaman **símbolos**.

- *Notación de Símbolos:* a, b, c, d, e, \dots
- *Notación de Alfabetos:* $\Sigma, \Gamma, \Pi, \dots$

Ejercicio

¿Qué alfabetos conoces?

Cadena

Cadena o Palabra (String)

Una **cadena** sobre un alfabeto Σ es cualquier sucesión (secuencia) finita de elementos de Σ .

- *Notación:* u, v, w, x, y, z, \dots

Cadena Vacía

La **cadena vacía** es la única cadena que no tiene símbolos y está dada sobre cualquier alfabeto Σ .

- *Notación:* $\lambda, \epsilon, \epsilon, \text{ o } \Lambda.$

Cadena

Cadena No Vacía

Una cadena no vacía u definida sobre un alfabeto Σ es de la forma $u = a_1 a_2 a_3 \cdots a_n$, donde $a_i \in \Sigma$ para $1 \leq i \leq n$. Además,

- u es una función $u : \{1, 2, \dots, n\} \mapsto \Sigma$.
- El valor de $u(j)$, para $1 \leq j \leq n$, es el símbolo en la j -ésima posición of u , i.e. $u(j) = a_j$.
- Notar que el símbolo $\alpha \in \Sigma$ puede aparecer en diferentes posiciones de u ; a cada una de estas se les llama **ocurrencias** de α en u .

Cadena

Longitud de una Cadena

La **longitud** de una cadena $u \in \Sigma^*$, denotada como $|u|$, se define como el número de símbolos de u incluyendo los repetidos. Más precisamente, la longitud de u es el número de posiciones que esta tiene. Es decir,

$$|u| = \begin{cases} 0, & \text{si } u = \lambda \\ n, & \text{si } u = a_1 a_2 \cdots a_n. \end{cases}$$

Conjunto de todas las Cadenas

El conjunto de todas las cadenas sobre el alfabeto Σ , incluyendo la cadena vacía, se denota como Σ^* .

Concatenación de Cadenas

Definición Descriptiva

Dado un alfabeto Σ y dos cadenas $u, v \in \Sigma^*$, la concatenación de u y v , denotada como $u \cdot v$ o uv , se define descriptivamente como :

- ① Si $v = \lambda$, $u \cdot \lambda = \lambda \cdot u = u$.
- ② Si $u = a_1 a_2 \cdots a_n$ y $v = b_1 b_2 \cdots b_m$, entonces

$$u \cdot v = a_1 a_2 \cdots a_n b_1 b_2 \cdots b_m.$$

Más formalmente, $w = uv$ si y solo si:

- $|w| = |u| + |v|$,
- $w(j) = u(j)$ para $1 \leq j \leq |u|$, y
- $w(|u| + j) = v(j)$ para $1 \leq j \leq |v|$.

Concatenación de Cadenas

Propiedades de la Concatenación

- La concatenación **es asociativa**, i.e., si $u, v, w \in \Sigma^*$, entonces

$$(uv)w = u(vw)$$

- La concatenación **no es conmutativa**. Es decir, si $u, v \in \Sigma^*$, en general $uv \neq vu$.

Ejercicio

Demostrar que la concatenación es asociativa usando la definición descriptiva.

Potenciación de Cadenas

Definición Descriptiva

Dada $u \in \Sigma^*$ y $n \in \mathbb{N}$, la cadena u^n se define descriptivamente como:

$$u^n = \begin{cases} \lambda, & \text{si } n = 0 \\ uuu \cdots u \text{ (n veces)}, & \text{si } n \geq 1. \end{cases}$$

Ejercicio

Usando la definición descriptiva, mostrar que $|w^{n+m}| = |w^n| + |w^m|$.

Reflexión de Cadenas

Definición Descriptiva

La **reflexión** o **inversa** de una cadena $u \in \Sigma^*$, denotada como u^R o u^{-1} , se define descriptivamente como:

$$u^R = \begin{cases} \lambda, & \text{si } u = \lambda \\ a_n a_{n-1} \cdots a_2 a_1, & \text{si } u = a_1 a_2 \cdots a_{n-1} a_n \end{cases}$$

Propiedades

- 1 $(u^R)^R = u$ para $u \in \Sigma^*$.
- 2 $(uv)^R = v^R u^R$ para todas las cadenas $u, v \in \Sigma^*$

Ejercicio

Generalizar la Propiedad 2 a la concatenación de n cadenas, $n \geq 2$.

Outline

- 1 Alfabetos y Cadenas
 - Definiciones Básicas de Alfabetos y Cadenas
 - Definiciones y Demostraciones Recursivas
- 2 Lenguajes
 - Definición
 - Operaciones entre Lenguajes
- 3 Lenguajes Regulares
 - Lenguajes y Expresiones Regulares
 - Expresiones Regulares en UNIX
 - Aplicaciones de de Expresiones Regulares

Conjunto

Definición Recursiva

Un conjunto se define recursivamente por medio de 3 cláusulas:

- 1 **Cláusula Básica:** Se especifican los elementos más sencillos (o básicos) de S .
- 2 **Cláusula Recursiva:** Se especifican reglas para la formación de nuevos elementos de S a partir de elementos ya conocidos de S .
- 3 **Cláusula de Exclusión:** Establece que los elementos de S se pueden obtener únicamente utilizando las Cláusulas 1 y 2.

Conjunto de todas las Cadenas

Definición Recursiva

Dado un alfabeto Σ , el conjunto de todas las cadenas Σ^* se define como:

- 1 $\lambda \in \Sigma^*$.
- 2 Si $u \in \Sigma^*$, entonces $ua \in \Sigma^*$ para todo $a \in \Sigma$.

Concepto sobre Cadena

Definición Recursiva

Dado un alfabeto Σ , para definir un concepto C sobre todas las cadenas en Σ^* se utilizan dos cláusulas:

- 1 Se define $C(\lambda)$.
- 2 Se define $C(ua)$ en términos de $C(u)$ para toda $u \in \Sigma^*$ y para todo $a \in \Sigma$.

Ejercicio

Defina longitud de cadena de manera recursiva.

Recursión sobre Cadenas

Definición Recursiva

Dado un alfabeto Σ , es posible demostrar recursivamente que todas las cadenas en Σ^* satisfacen una propiedad P . A este tipo de razonamiento recursivo se le conoce como **recursión sobre cadenas** y consta de dos pasos:

- 1 Se demuestra $P(\lambda)$.
- 2 Se demuestra $P(u) \Rightarrow P(ua)$ para toda $u \in \Sigma^*$ y para todo $a \in \Sigma$.

Concatenación de Cadenas

Definición Recursiva

Sea $u \in \Sigma^*$. La concatenación de cadenas se define recursivamente como:

- 1 $u \cdot \lambda = \lambda \cdot u = u.$
- 2 $u \cdot (va) = (u \cdot v)a$, donde $a \in \Sigma$ y $v \in \Sigma^*$.

Ejercicio

Usando la definición recursiva, demostrar que la concatenación es asociativa: si $u, v, w \in \Sigma^*$, entonces $(uv)w = u(vw)$.

Potenciación de Cadenas

Definición Recursiva

Dada $u \in \Sigma^*$ y $n \in \mathbb{N}$, la cadena u^n se define inductivamente como:

- 1 $u^0 = \lambda$.
- 2 $u^{n+1} = u^n u$ para $n \geq 0$.

Reflexión de Cadenas

Ejercicio

Dar una definición recursiva de u^R .

Subcadena

Subcadena o Subpalabra (Substring)

Sean $u, v \in \Sigma^*$. La cadena v es una **subcadena** o **subpalabra** de u si existen cadenas $x, y \in \Sigma^*$ tales que $u = xvy$.

Prefijo

Sean $u, v \in \Sigma^*$. Un **prefijo** de u es una cadena v tal que $u = vw$ para alguna cadena $w \in \Sigma^*$. Además v es un **prefijo propio** de u si $u \neq v$.

Sufijo

Sean $u, v \in \Sigma^*$. Un **sufijo** de u es una cadena v tal que $u = wv$ para alguna cadena $w \in \Sigma^*$. Además v es un **sufijo propio** de u si $u \neq v$.

Orden Lexicográfico de Cadenas

- Sea $\Sigma = \{s_1, s_2, \dots, s_k\}$ un alfabeto en el que los símbolos tienen un orden predeterminado: $s_1 < s_2 < \dots < s_k$.
- En el conjunto Σ^* se define el **orden lexicográfico** de las cadenas, denotado como $<$, de la siguiente manera.
- Sea $u, v \in \Sigma^*$ tales que

$$u = a_1 a_2 \cdots a_m, \text{ where } a_i \in \Sigma, \text{ for } i \text{ in } 1 \leq i \leq m$$

$$v = b_1 b_2 \cdots b_n, \text{ where } b_i \in \Sigma, \text{ for } i \text{ in } 1 \leq i \leq n.$$

- Entonces, se define $u < v$ si
 - 1 $|u| < |v|$, i.e. $m < n$, or
 - 2 $|u| = |v|$ y para algún índice i , $1 \leq i \leq m$, se cumple que

$$a_1 = b_1, a_2 = b_2, \dots, a_{i-1} = b_{i-1}, a_i < b_i.$$

- 3 $\lambda < u, \forall u \in \Sigma^* : |u| > 0.$

Orden Lexicográfico de Cadenas

Ejercicio

Sea $\Sigma = \{a, b, c, d\}$ un alfabeto en el que los símbolos tienen un orden predeterminado: $a < b < c < d$. Hallar la cadena que sigue a u en el orden lexicográfico:

- $u = dbd$
- $u = dabcdd$
- $u = acbd$
- $u = dcaddd$
- $u = bbb$

Outline

- 1 Alfabetos y Cadenas
 - Definiciones Básicas de Alfabetos y Cadenas
 - Definiciones y Demostraciones Recursivas
- 2 Lenguajes
 - Definición
 - Operaciones entre Lenguajes
- 3 Lenguajes Regulares
 - Lenguajes y Expresiones Regulares
 - Expresiones Regulares en UNIX
 - Aplicaciones de de Expresiones Regulares

Outline

- 1 Alfabetos y Cadenas
 - Definiciones Básicas de Alfabetos y Cadenas
 - Definiciones y Demostraciones Recursivas
- 2 Lenguajes
 - Definición
 - Operaciones entre Lenguajes
- 3 Lenguajes Regulares
 - Lenguajes y Expresiones Regulares
 - Expresiones Regulares en UNIX
 - Aplicaciones de de Expresiones Regulares

Lenguaje

- Un lenguaje L sobre un alfabeto Σ es un subconjunto $L \subseteq \Sigma^*$.
- Todo lenguaje L satisface $\emptyset \subseteq L \subseteq \Sigma^*$ y es finito o infinito.
- **Notación:** $A, B, C, \dots, L, M, N, \dots$
- Si P es una propiedad de las cadenas de Σ^* , el lenguaje L de las cadenas que satisfacen la propiedad P se denota como $L = \{u \in \Sigma^* : P(u)\}$.




Figura 1: Lenguaje (Tomado de [1])

Outline

- 1 Alfabetos y Cadenas
 - Definiciones Básicas de Alfabetos y Cadenas
 - Definiciones y Demostraciones Recursivas
- 2 Lenguajes
 - Definición
 - Operaciones entre Lenguajes
- 3 Lenguajes Regulares
 - Lenguajes y Expresiones Regulares
 - Expresiones Regulares en UNIX
 - Aplicaciones de de Expresiones Regulares

Operaciones entre Lenguajes

Operaciones Conjuntistas o Booleanas

Sean $A, B \subseteq \Sigma^*$. Los siguientes también son lenguajes sobre Σ :

- **Unión:** $A \cup B = \{u \in \Sigma^* : u \in A \vee u \in B\}$.
- **Intersección:** $A \cap B = \{u \in \Sigma^* : u \in A \wedge u \in B\}$.
- **Diferencia:** $A - B = A \setminus B = \{u \in \Sigma^* : u \in A \wedge u \notin B\}$.
- **Diferencia Simétrica:** $A \triangle B = \{u \in \Sigma^* : u \in A \vee u \in B\}$.
- **Complemento:** $\bar{A} = \Sigma^* - A = \{u \in \Sigma^* : u \notin A\}$.

Operaciones entre Lenguajes

Operaciones Lingüísticas

Las operaciones lingüísticas sobre los lenguajes son:

- Concatenación.
- Potenciación.
- Reflexión.
- Clausura.

Concatenación de Lenguajes

Definición

Sean $A, B \subseteq \Sigma^*$. La concatenación de A y B , denotada como $A \cdot B$ o AB , se define como:

$$A \cdot B = AB = \{uv : u \in A, v \in B\}.$$

En general, $AB \neq BA$.

Propiedades de la Concatenación

Sean $A, B, C \subseteq \Sigma^*$. Entonces,

① $A \cdot \emptyset = \emptyset \cdot A = \emptyset.$

② $A \cdot \{\lambda\} = \{\lambda\} \cdot A = A.$

③ **Propiedad Asociativa:** $A \cdot (B \cdot C) = (A \cdot B) \cdot C.$

④ **Distributividad con respecto a la Unión:**

$$A \cdot (B \cup C) = A \cdot B \cup A \cdot C,$$

$$(B \cup C) \cdot A = B \cdot A \cup C \cdot A.$$

⑤ **Distributividad Generalizada con respecto a la Unión:** Sea $\{B_i\}_{i \in I}$ una familia indexada de lenguajes sobre Σ , i.e. $B_i \subseteq \Sigma^*$, entonces:

$$A \cdot \bigcup_{i \in I} B_i = \bigcup_{i \in I} (A \cdot B_i) \quad \text{y} \quad \left(\bigcup_{i \in I} B_i \right) \cdot A = \bigcup_{i \in I} (B_i \cdot A).$$

Propiedades de la Concatenación

Sean $A, B, C \subseteq \Sigma^*$. Entonces,

- La propiedad asociativa permite escribir concatenaciones sin paréntesis, i.e. ABC .
- En general, **no se cumple** que $A \cdot (B \cap C) = A \cdot B \cap A \cdot C$.
Contraejemplo: $\Sigma = \{a\}$, $A = \{a, \lambda\}$, $B = \{\lambda\}$ y $C = \{a\}$.

Propiedades de la Concatenación

Ejercicio

- 1 Dar un ejemplo de un alfabeto Σ y dos lenguajes diferentes $A, B \subseteq \Sigma^*$ tales que $AB = BA$.
- 2 Dar un ejemplo de un alfabeto Σ y tres lenguajes A, B y C sobre Σ , diferentes entre sí, tales que $A \cdot (B \cap C) = AB \cap AC$.
- 3 Demuestre que $A \cdot (B \cap C) \subseteq AB \cap AC$. Muestre un ejemplo.
- 4 Muestre que $AB \cap AC \subseteq A \cdot (B \cap C)$ no se cumple en el caso general a través de un contraejemplo.

Potencias de un Lenguaje

Definición Descriptiva

Dado un lenguaje $A \subseteq \Sigma^*$ y un número $n \in \mathbb{N}$, se define A^n de la siguiente forma:

- 1 $A^0 = \{\lambda\}$.
- 2 $A^n = AA \cdots A$ (n veces) $= \{u_1 \cdots u_n : (\forall i)(u_i \in A), 1 \leq i \leq n\}$.

Definición Recursiva

Dado un lenguaje $A \subseteq \Sigma^*$ y un número $n \in \mathbb{N}$, se define A^n de la siguiente forma:

- 1 $A^0 = \{\lambda\}$.
- 2 $A^{n+1} = A^n \cdot A$, para todo $n \geq 0$.

Clausura de Kleene de un Lenguaje

Definición Descriptiva

La **clausura de Kleene**, **estrella de Kleene** o **estrella** de un lenguaje $A \subseteq \Sigma^*$, denotada como A^* es la unión de todas las potencias de A , i.e.

$$\begin{aligned} A^* &= \bigcup_{n \geq 0} A^n = A^0 \cup A^1 \cup A^2 \cup \dots \\ &= \{u_1 \cdots u_n : (\forall i)(u_i \in A), 1 \leq i \leq n, n \geq 0\}. \end{aligned}$$

Definición Recursiva

La **estrella** de un lenguaje $A \subseteq \Sigma^*$, denotada como A^* , se define recursivamente como:

- ① $\lambda \in A^*$.
- ② Si $u \in A^*$ y $v \in A$, entonces $u \cdot v \in A^*$.

Clausura Positiva de un Lenguaje

Definición Descriptiva

La **clausura positiva** de un lenguaje $A \subseteq \Sigma^*$, denotado como A^+ es:

$$\begin{aligned} A^+ &= \bigcup_{n \geq 1} A^n = A^1 \cup A^2 \cup \dots \\ &= \{u_1 \cdots u_n : (\forall i)(u_i \in A), 1 \leq i \leq n, n \geq 1\}. \end{aligned}$$

Definición Recursiva

La **clausura positiva** de un lenguaje $A \subseteq \Sigma^*$, denotada como A^+ , se define recursivamente como:

- ① Si $u \in A$, entonces $u \in A^+$.
- ② Si $u \in A^+$ y $v \in A$, entonces $u \cdot v \in A^+$.

Propiedades de las Clausuras

Sea $A \subseteq \Sigma^*$. Entonces,

- 1 $A^* = A^+ \cup \{\lambda\}$.
- 2 $A^* = A^+$ si y solamente si $\lambda \in A$.
- 3 $A^+ = A^* \cdot A = A \cdot A^*$.
- 4 $A^* \cdot A^* = A^*$.
- 5 $(A^*)^n = A^*$, para todo $n \geq 1$.
- 6 $A^+ \cdot A^+ \subseteq A^+$. En general, $A^+ \cdot A^+ \neq A^+$.
- 7 $(A^*)^* = A^*$.
- 8 $(A^*)^+ = A^*$.
- 9 $(A^+)^* = A^*$.
- 10 $(A^+)^+ = A^+$.

Propiedades de las Clausuras

Sea $A, B \subseteq \Sigma^*$. Entonces,

- 1 Si $A \subseteq B$, entonces $A^* \subseteq B^*$.
- 2 $(A \cup B)^* = (A^*B^*)^* = (B^*A^*)^*$.

En general, la igualdad $(A \cup B)^* = A^* \cup B^*$ **no es válida**.

Ejercicio

- 1 Demostrar las propiedades 1 y 2.
- 2 Mostrar ejemplos de las propiedades 1 y 2.
- 3 Mostrar un ejemplo en que se cumpla $(A \cup B)^* = A^* \cup B^*$.
- 4 Mostrar un contraejemplo de $(A \cup B)^* = A^* \cup B^*$.

Reflexión o Inverso de un Lenguaje

Sea $A \subseteq \Sigma^*$. Se define como la **reflexión**, **reverso** o **inverso** de A , denotado como A^R , así:

$$A^R = \{u^R : u \in A\}.$$

Propiedades de la Reflexión

- 1 $(A \cdot B)^R = B^R \cdot A^R.$
- 2 $(A \cup B)^R = A^R \cup B^R.$
- 3 $(A \cap B)^R = A^R \cap B^R.$
- 4 $(A^R)^R = A.$
- 5 $(A^*)^R = (A^R)^*.$
- 6 $(A^+)^R = (A^R)^+.$

Ejercicio

- 1 Demostrar estas propiedades.
- 2 ¿Se pueden extender las Propiedades 2 y 3 a uniones/intersecciones de un número arbitrario de lenguajes?

Outline

- 1 Alfabetos y Cadenas
 - Definiciones Básicas de Alfabetos y Cadenas
 - Definiciones y Demostraciones Recursivas
- 2 Lenguajes
 - Definición
 - Operaciones entre Lenguajes
- 3 Lenguajes Regulares
 - Lenguajes y Expresiones Regulares
 - Expresiones Regulares en UNIX
 - Aplicaciones de de Expresiones Regulares

Outline

- 1 Alfabetos y Cadenas
 - Definiciones Básicas de Alfabetos y Cadenas
 - Definiciones y Demostraciones Recursivas
- 2 Lenguajes
 - Definición
 - Operaciones entre Lenguajes
- 3 Lenguajes Regulares
 - Lenguajes y Expresiones Regulares
 - Expresiones Regulares en UNIX
 - Aplicaciones de de Expresiones Regulares

Lenguajes Regulares

Definición Recursiva

La colección de todos los **lenguajes regulares** sobre un alfabeto Σ se define como:

- ① \emptyset , $\{\lambda\}$ y $\{a\}$, $a \in \Sigma$, son **lenguajes regulares básicos** sobre Σ .
- ② Si A y B son lenguajes regulares sobre Σ , también lo son:
 - $A \cup B$.
 - $A \cdot B$.
 - A^* .

Lenguajes Regulares

Operaciones Regulares

- Unión.
- Concatenación.
- Estrella de Kleene.

Propiedades

- Todo lenguaje finito es regular ya que se puede obtener a partir de una unión finita.
- Si $\{A_i\}_{i \in \mathcal{I}}$ es una familia infinita de lenguajes regulares, la unión de estos, i.e. $\bigcup_{i \in \mathcal{I}} A_i$, no necesariamente es regular.

Lenguajes Regulares

Ejercicio

Sea $\Sigma = \{a, b\}$. Muestre que los siguientes lenguajes son regulares:

- ❶ Lenguaje de todas las cadenas en Σ^* .
- ❷ Lenguaje de todas las cadenas en Σ^+ .
- ❸ Lenguaje de todas las cadenas que tienen exactamente una a .
- ❹ Lenguaje de todas las cadenas que comienzan con una b .
- ❺ Lenguaje de todas las cadenas que contienen la subcadena ba .
- ❻ Lenguaje de las cadenas sobre Σ que tienen exactamente longitud 2.
- ❼ Lenguaje de las cadenas sobre Σ que tienen al menos longitud 2.
- ❽ Lenguaje de las cadenas sobre Σ que tienen máximo longitud 2.

Expresiones Regulares

Definición Recursiva

Las **expresiones regulares** sobre un alfabeto Σ se definen como:

1 Expresiones Regulares Básicas:

- \emptyset es una expresión regular que representa al lenguaje \emptyset .
- λ es una expresión regular que representa al lenguaje $\{\lambda\}$.
- a es una expresión regular que representa al lenguaje $\{a\}$, para cada $a \in \Sigma$.

2 Si R y S son expresiones regulares sobre Σ que representan a los lenguajes regulares A y B , respectivamente, entonces:

- $(R \cup S)$ es una expresión regular que representa al lenguaje $A \cup B$.
- (RS) es una expresión regular que representa al lenguaje $A \cdot B$.
- $(R)^*$ es una expresión regular que representa al lenguaje A^* .

Expresiones Regulares

Otra Notación

Denótese con $L[R]$ al lenguaje representado por la expresión regular R . Las expresiones regulares se pueden presentar como:

- ❶ **Expresiones Regulares Básicas:** \emptyset , λ y a (donde $a \in \Sigma$) son expresiones regulares tales que:
 - $L[\emptyset] = \emptyset$.
 - $L[\lambda] = \{\lambda\}$.
 - $L[a] = \{a\}$, para cada $a \in \Sigma$.
- ❷ Si R y S son expresiones regulares entonces:
 - $L[(R \cup S)] = L[R] \cup L[S]$.
 - $L[(RS)] = L[R] \cdot L[S]$.
 - $L[(R)^*] = (L[R])^*$.

Expresiones Regulares

Ejercicio

Sea $\Sigma = \{a, b\}$. Construya expresiones regulares para los siguientes lenguajes:

- 1 Lenguaje de todas las cadenas en Σ^* .
- 2 Lenguaje de todas las cadenas en Σ^+ .
- 3 Lenguaje de todas las cadenas que tienen exactamente una a .
- 4 Lenguaje de todas las cadenas que comienzan con una b .
- 5 Lenguaje de todas las cadenas que contienen la subcadena ba .
- 6 Lenguaje de las cadenas sobre Σ que tienen exactamente longitud 2.
- 7 Lenguaje de las cadenas sobre Σ que tienen al menos longitud 2.
- 8 Lenguaje de las cadenas sobre Σ que tienen máximo longitud 2.

Expresiones Regulares

Algunas Propiedades

- La representación de lenguajes regulares por medio de expresiones regulares no es única.
- En expresiones regulares también se permite el uso de potencias.
- Por la propiedad $A^+ = A^* \cdot A = A \cdot A^*$, se permite el uso de la clausura positiva en expresiones regulares.

Ejercicio

Encuentre otras expresiones regulares que representen el mismo lenguaje que las siguientes:

- 1 $(a \cup b)^*$
- 2 $(a^+ \cup b)ab^+$
- 3 $(a \cup b)^+ \cup a^+b^+$

Expresiones Regulares

Ejercicio

Sea $\Sigma = \{a, b\}$. Construya expresiones regulares para los siguientes lenguajes de las cadenas u sobre Σ tales que:

- ① $u \in \Sigma^*$.
- ② tienen exactamente una a .
- ③ comienzan con a .
- ④ terminan con a .
- ⑤ contienen la subcadena ba .
- ⑥ tienen longitud par.
- ⑦ tienen longitud impar.
- ⑧ su longitud es múltiplo de 3.
- ⑨ su longitud cumple que $|u| \bmod 3 = 2$.

Expresiones Regulares

Algunas Propiedades

- En las expresiones regulares se usan reglas de precedencia. El orden es:
 - 1 * Estrella de Kleene.
 - 2 · Concatenación.
 - 3 \cup Unión.
- Sean L, R y S expresiones regulares. La propiedad $L[R(S \cup T)] = L[RS \cup RT]$ permite distribuir o “factorizar” para obtener nuevas expresiones regulares.

Expresiones Regulares

Ejercicio

Sea $\Sigma = \{a, b, c\}$. Construya expresiones regulares para los siguientes lenguajes:

- ① su penúltimo símbolo es una a .
- ② su número de a 'es es exactamente 2.
- ③ su número de a 'es es al menos 2.
- ④ su número de a 'es es máximo 2.
- ⑤ su número de a 'es es par.
- ⑥ no contienen dos a 'es consecutivas.
- ⑦ no contienen la subcadena bc .
- ⑧ empiezan y terminan con el mismo símbolo.
- ⑨ empiezan y terminan con diferentes símbolos.

Outline

- 1 Alfabetos y Cadenas
 - Definiciones Básicas de Alfabetos y Cadenas
 - Definiciones y Demostraciones Recursivas
- 2 Lenguajes
 - Definición
 - Operaciones entre Lenguajes
- 3 Lenguajes Regulares
 - Lenguajes y Expresiones Regulares
 - **Expresiones Regulares en UNIX**
 - Aplicaciones de de Expresiones Regulares

Expresiones Regulares en UNIX

grep

- **G**lobally search for a **R**egular **E**xpression and **P**rint matching lines.
- Funciona de forma similar a egrep.

egrep

- **E**xtended **G**lobal search for a **R**egular **E**xpression and **P**rint matching lines.
- Usualmente usado en consolas de Unix.
- Dado un archivo de texto `archivo.txt`, y una expresión regular `re`, ejecutar el comando: `egrep 're' archivo.txt`.
- La ejecución de este comando muestra las líneas que satisfacen la expresión regular señalando las partes exactas que la satisfacen.

Expresiones Regulares en UNIX

Concatenación

Escribir caracteres o palabras concatenadas uno a continuación del otro.

Unión

.	cualquier caracter
\w	caracteres que forman palabras
\W	caracteres que no forman palabras
[a+d]	cualquier caracter en $a \cup + \cup d$
[a-c]	cualquier caracter en $a \cup b \cup c$
[^abd]	cualquier caracter que no pertenezca a $(a \cup b \cup d)$
[^a-c]	cualquier caracter que no pertenezca a $(a \cup b \cup c)$
a b	cualquier caracter en $(a \cup b)$
Homero Marge	que sea Homero o Marge

Expresiones Regulares en UNIX

Más de Unión

Los conjuntos de caracteres de POSIX agrupan grupos de caracteres:

<code>[:alpha:]</code>	caracteres alfabéticos
<code>[:lower:]</code>	caracteres alfabéticos en minúscula
<code>[:upper:]</code>	caracteres alfabéticos en mayúscula
<code>[:digit:]</code>	dígitos
<code>[:xdigit:]</code>	dígitos incluyendo hexadecimales
<code>[:alnum:]</code>	caracteres alfanuméricos
<code>[:punct:]</code>	signos de puntuación
<code>[:space:]</code>	espacios en blanco
<code>[:blank:]</code>	espacios en blanco, tabulaciones, etc
<code>[:print:]</code>	caracteres imprimibles

Expresiones Regulares en UNIX

Repetición

$p?$	cero o una ocurrencia de p
p^+	una o más ocurrencias consecutivas de p
p^*	cero o más ocurrencias consecutivas de p
$(pa)^*$	cero o más ocurrencias consecutivas de pa
$p\{2\}$	dos pes consecutivas
$p\{2,4\}$	de 2 a 4 pes consecutivas
$p\{2,\}$	mínimo dos pes consecutivas
$p\{,4\}$	máximo dos pes consecutivas
$(pp)\{,4\}$	máximo 4 ocurrencias consecutivas de pp

Expresiones Regulares en UNIX

Caracteres de escape

- Algunos caracteres tienen una función especial en la búsqueda de expresiones regulares. Por ejemplo: `[] () {} .* ?`.
- Para referirse a estos como tal, se deben preceder de `\`

Palabras y Líneas

<code>^a</code>	líneas que comiencen por <i>a</i>
<code>a\$</code>	líneas que terminen en <i>a</i>
<code>\< a</code>	palabras que comienzan por <i>a</i>
<code>a \></code>	palabras que terminan en <i>a</i>

Outline

- 1 Alfabetos y Cadenas
 - Definiciones Básicas de Alfabetos y Cadenas
 - Definiciones y Demostraciones Recursivas
- 2 Lenguajes
 - Definición
 - Operaciones entre Lenguajes
- 3 Lenguajes Regulares
 - Lenguajes y Expresiones Regulares
 - Expresiones Regulares en UNIX
 - Aplicaciones de de Expresiones Regulares

Análisis Léxico

Analizador Léxico

- Un analizador léxico realiza las siguientes operaciones:
 - 1 Examina el código fuente.
 - 2 Reconoce los tokens: subcadenas de caracteres que constituyen una unidad lógica; por ejemplo, palabras reservadas e identificadores.
- Las expresiones regulares son útiles para describir los tokens.
- Antes de estas herramientas basadas en expresiones regulares, la implementación de analizadores léxicos tomaba meses; ahora días.
- La modificación del analizador léxico usualmente consiste en la modificación de alguna de las expresiones regulares.

Análisis Léxico

Los comandos `lex` y `flex` de Unix/GNU convierten expresiones regulares en autómatas finitos deterministas para generar una función eficiente que parte el código fuente en tokens.

```
else                {return(ELSE);}  
  
[A-Za-z][A-Za-z0-9]*  {code to enter the found identifier  
                        in the symbol table;  
                        return(ID);  
                        }  
  
>=                 {return(GE);}  
  
=                   {return(EQ);}  
  
...
```

Figura 2: Fragmento de entrada para `lex`. (Tomado de [3])

Análisis Léxico

- Las expresiones regulares también son útiles para el análisis léxico de números de punto flotante, cadenas de caracteres, comentario y palabras reservadas.
- Se construye un autómata que acepte la unión de estas expresiones regulares, de manera que se pueda:
 - saber si algún elemento se reconoce.
 - determinar qué se reconoció.
 - priorizar a qué categoría se asigna a un elemento. Por ejemplo, `else`.

Búsqueda de Patrones en Texto

- Las expresiones regulares útiles para definir patrones de interés.
- No se han desarrollado herramientas tan potentes como las del análisis léxico.
- Se empieza por una definición general del patrón a buscar. Luego se refina con casos más específicos.
- Se puede usar para
 - reconocer páginas Web.
 - crear listas de correo.
 - clasificar negocios por su locación.
 - reconocer direcciones.

```
'[0-9]+[A-Z]? [A-Z][a-z]*([A-Z][a-z]*)*  
(Street|St\.|Avenue|Ave\.|Road|Rd\.)'
```

Bibliografía

- ① Rodrigo De Castro Korgi. **Notas de Clase de Introducción a la Teoría de la Computación**. 2023.
- ② Harry R. Lewis, Christos H. Papadimitriou. **Elements of the Theory of Computation**. Prentice Hall. 1998.
- ③ John E. Hopcroft, Rajeev Motwani, Jeffrey D. Ullman. **Introduction to Automata Theory, Languages and Computation, Third Edition**. Pearson. 2006.
- ④ <http://manpages.ubuntu.com/manpages/focal/es/man1/grep.1.html>